

Tableau récapitulatif des décisions et actions de nettoyage

Le présent tableau consolide l'ensemble des décisions méthodologiques et opérationnelles prises au cours des sections précédentes. Il constitue le référentiel unique pour l'exécution du pipeline de nettoyage des données du projet Seattle Energy Benchmarking 2016. Chaque ligne correspond à une action atomique, justifiée par les analyses diagnostiques menées et ordonnée selon une séquence logique d'exécution.

Ordre d'exécution du pipeline de nettoyage

Nous avons défini la séquence d'exécution suivante pour garantir l'intégrité de la modélisation :

1. **Section 0** : Filtrage du périmètre.
2. **Section 2** : Audit de cohérence physique.
3. **Section 3** : Détection des outliers statistiques.
4. **Section 1** : Gestion des valeurs manquantes et suppression des colonnes.

Justification et choix méthodologique

Nous avons choisi de placer la Section 1 en dernière position car l'imputation des valeurs manquantes ou la suppression préventive de colonnes risqueraient de masquer des réalités physiques ou de biaiser les distributions statistiques nécessaires au calcul des bornes IQR. En auditant d'abord la cohérence arithmétique (Section 2) et les déviations extrêmes (Section 3), nous travaillons sur un signal pur, non pollué par des valeurs artificielles injectées lors d'une imputation. Cet ordre permet de qualifier précisément chaque bâtiment avant de décider si son manque de données justifie une exclusion finale.

Nous précisons que dans notre environnement de travail, l'ordre initial importait peu car nos fonctions d'audit ne modifiaient pas le jeu de données brutes. Les algorithmes statistiques utilisés ignorent nativement les valeurs nulles, ce qui garantit que le calcul de nos seuils reste identique, que les valeurs manquantes aient été flagguées ou non. Cette robustesse nous a permis d'isoler les incohérences physiques majeures sans dénaturer la représentativité du parc immobilier de Seattle pour la prédiction des émissions de CO₂.

Remarque méthodologique sur l'imputation par strate

Lors de l'application des diagnostics et des audits de la **Section 1**, nous avons constaté que certains sous-groupes d'usage (**PrimaryPropertyType**) étaient statistiquement sous-représentés ou ne présentaient aucune donnée valide pour certaines variables structurelles (notamment le nombre d'étages).

Face à ces "tranches vides" (détectées par les avertissements de type *Mean of empty slice*), nous avons pris la décision d'implémenter une **imputation en cascade** :

- **Priorité à la spécificité** : L'imputation est d'abord tentée au niveau de la sous-catégorie d'usage pour préserver la cohérence architecturale.
- **Sécurité par palier** : En cas d'absence de référentiel dans la sous-catégorie, le pipeline bascule sur la médiane globale du projet en dernier ressort.
- **Audit de fiabilité** : Cette décision permet de garantir un dataset 100% exploitable par les algorithmes de Machine Learning tout en marquant explicitement (via la colonne **IsZeroFloorReported**) les lignes dont la valeur a été reconstituée.

Remarque méthodologique sur la fiabilisation des intensités énergétiques (EUI)

La validité d'un modèle de prédiction des émissions de CO₂ dépend directement de la cohérence interne des variables d'intensité. L'EUI (Energy Use Intensity) constitue l'indicateur pivot du dataset puisqu'il normalise la consommation énergétique par la dimension spatiale du bâtiment. Cependant, l'analyse diagnostique a révélé que les données d'intensité originales étaient inexploitables en l'état pour deux raisons fondamentales. D'une part, la correction préalable des consommations normalisées (**Weather Normalized**) a mécaniquement rendu les intensités d'origine obsolètes. D'autre part, la détection d'observations

affichant une intensité nulle malgré une consommation positive signalait une corruption logique du reporting initial (données manquantes ou erreurs de calcul tiers).

Restauration de la cohérence physique (Weather Normalized)

Nous avons identifié une faille critique dans les données d'origine : de nombreuses lignes affichaient une consommation brute strictement positive, alors que les variables normalisées météo (**SiteEnergyUseWN**, **SiteEUIWN** et **SourceEUIWN**) étaient nulles ou manquantes. Physiquement, un bâtiment qui consomme de l'énergie ne peut pas avoir une consommation normalisée nulle. Pour corriger ce biais qui aurait conduit à écarter injustement des bâtiments valides ou à fausser les moyennes, nous avons forcé la copie de la valeur brute vers la variable normalisée dès que cette anomalie était détectée. Cette étape de synchronisation garantit que l'impact climatique est neutralisé sans ignorer la réalité de la consommation énergétique mesurée.

Justification du référentiel de surface

Pour que nos calculs d'intensité soient fiables, nous avons dû déterminer s'il fallait diviser la consommation par la surface totale de la parcelle ou par la surface brute du bâtiment . Nos tests ont conclu que seule la surface bâtie permet de retrouver exactement les valeurs déclarées par la ville de Seattle. En isolant ainsi l'enveloppe thermique, nous évitons de diluer artificiellement la consommation des bâtiments dotés de vastes parkings ou jardins. Ce choix nous permet de démasquer l'inefficacité réelle des structures qui, autrement, auraient paru performantes grâce à l'étendue de leur terrain.

Ce choix de restaurer les valeurs normalisées nous a imposé de recalculer systématiquement les intensités énergétiques (EUI) correspondantes pour maintenir une cohérence totale dans notre dataset. Nous ne pouvions pas nous contenter des ratios déclarés, car ils ne reflétaient plus la réalité physique après notre intervention sur les consommations globales. En recalculant nous-mêmes ces indicateurs, nous garantissons que chaque intensité repose sur les mêmes règles de calcul et sur les surfaces bâties réelles.

Structure du tableau

Le tableau est organisé en colonnes distinctes permettant une traçabilité complète des opérations de nettoyage. La colonne Ordre définit la séquence d'exécution des actions, garantissant que les dépendances entre transformations sont respectées. La colonne Variable cible identifie précisément la ou les variables concernées par l'action. La colonne Action technique spécifie l'opération concrète à implémenter dans le code. La colonne Justification méthodologique explicite le raisonnement analytique qui sous-tend la décision. Enfin, la colonne Validation attendue précise les contrôles qualité à effectuer après exécution.

Section 0

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
1	BuildingType et PrimaryPropertyType	Filtrer et conserver uniquement les observations où BuildingType est différent de Multifamily MR (5-9), Multifamily HR (10+) et Multifamily LR (1-4) et PrimaryPropertyType est vraiment non-residentiel	Le périmètre du projet est strictement limité aux bâtiments non résidentiels. Les bâtiments résidentiels obéissent à des logiques de consommation énergétique structurellement différentes. Leur inclusion introduirait une hétérogénéité incompatible avec l'objectif de modélisation. Cette restriction est conforme au cahier des charges métier et assure la cohérence statistique des analyses ultérieures.	Vérifier que BuildingType ne contient plus aucune des trois modalités résidentielles. Contrôler que la dimension du dataframe a diminué du nombre attendu de lignes résidentielles. Confirmer que toutes les modalités restantes correspondent bien à des usages non résidentiels.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
2	BuildingType	Remplacer la modalité Nonresidential WA par NonResidential	L'analyse du bâtiment identifiant 50101 (Burke Museum, classé University dans PrimaryPropertyType) révèle une incohérence taxonomique. La modalité Nonresidential WA ne possède qu'une seule occurrence et son usage correspond à la définition standard de NonResidential. Cette harmonisation élimine une catégorie singleton qui n'apporte aucune valeur discriminante et risque de poser des problèmes lors de l'encodage ou de la validation croisée.	Vérifier que la modalité Nonresidential WA a totalement disparu du jeu de données. Confirmer que le nombre d'occurrences de NonResidential a augmenté d'une unité. S'assurer que le bâtiment 50101 est désormais classé NonResidential.

Section 2

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
3	PropertyGFATotal	Supprimer toutes les lignes où PropertyGFATotal est inférieur ou égal à zéro	Une surface totale nulle ou négative constitue une impossibilité physique absolue. Un bâtiment ne peut exister sans occuper d'espace. Cette anomalie révèle soit une erreur de saisie critique, soit une absence totale de données exploitables pour le calcul des intensités énergétiques. La conservation de telles lignes corromprait mécaniquement tous les ratios énergétiques par unité de surface, rendant impossible la comparaison entre bâtiments et faussant les distributions des variables dérivées comme l'EUI (Energy Use Intensity).	Vérifier qu'aucune observation ne présente une valeur de PropertyGFATotal inférieure ou égale à zéro après nettoyage. Confirmer que toutes les valeurs de PropertyGFATotal sont strictement positives. Documenter le nombre exact de lignes supprimées pour cette raison dans les logs de traçabilité.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
4	SiteEnergyUse(kBtu), TotalGHGEmissions, Electricity(kBtu), NaturalGas(kBtu)	Supprimer toutes les lignes présentant au moins une valeur strictement négative dans ces variables énergétiques	<p>Les variables de consommation énergétique et d'émissions de gaz à effet de serre ne peuvent être négatives par définition physique. Une consommation négative violerait le premier principe de la thermodynamique. Ces valeurs traduisent des erreurs de saisie, des problèmes de conversion d'unités ou des corruptions de données lors de l'export. Leur maintien introduirait un biais systématique dans l'estimation des distributions et pourrait conduire le modèle à apprendre des patterns aberrants. Une seule variable négative suffit à invalider l'ensemble de l'observation car elle signale une défaillance globale du processus de reporting pour ce bâtiment.</p>	Confirmer l'absence totale de valeurs négatives dans les quatre variables énergétiques critiques après nettoyage. Contrôler que les distributions de ces variables ne présentent plus d'anomalies dans les queues de distribution négatives. Documenter précisément quelles variables étaient négatives pour chaque ligne supprimée afin d'identifier d'éventuels patterns systématiques d'erreur.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
5	SiteEnergyUseWN(kBtu), SiteEUIWN(kBtu/sf), SourceEUIWN(kBtu/sf)	Pour toutes les lignes où la variable brute est strictement positive mais la variable Weather Normalized est nulle ou manquante, copier la valeur brute dans la variable normalisée	Les variables Weather Normalized synchronisées avec leurs équivalents bruts garantissent la cohérence déterministe entre consommation et intensité. Cette correction technique préserve l'exploitabilité des observations en évitant les divisions par zéro lors du recalcul des intensités énergétiques. L'hypothèse sous-jacente est que l'absence de correction météorologique est moins préjudiciable pour la modélisation qu'une valeur nulle aberrante qui corromprait les calculs d'intensité énergétique.	Vérifier que toutes les lignes avec énergie brute positive disposent désormais d'une valeur WN cohérente. Contrôler l'absence de valeurs nulles résiduelles dans les variables Weather Normalized lorsque les variables brutes sont positives. Valider que cette synchronisation n'a pas créé de nouvelles incohérences avec d'autres variables dérivées.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
6	NumberofFloors	Créer une variable binaire IsZeroFloorReported valant 1 si NumberofFloors était initialement inférieur ou égal à zéro et 0 sinon, puis créer une variable binaire IsAggregatedCampus valant 1 si BuildingType est égal à Campus et 0 sinon	<p>L'analyse qualitative de seize bâtiments déclarant zéro étage a révélé deux populations distinctes. D'une part, des structures individuelles massives comme le Grand Hyatt Seattle ou le centre commercial Pacific Place, pour lesquelles le zéro constitue manifestement une erreur de saisie ou une omission lors du reporting. D'autre part, des entités agrégées de type Campus comme l'University of Washington, pour lesquelles le concept d'étage perd son sens car il s'agit d'un ensemble de bâtiments distincts. La création de ces deux flags permet de préserver cette information structurelle tout en facilitant le traitement différencié ultérieur. Le flag IsZeroFloorReported servira d'indicateur de confiance pour les futures imputations, tandis que IsAggregatedCampus permettra au modèle de distinguer les agrégats multi-bâtiments des structures uniques.</p>	Vérifier que IsZeroFloorReported contient exactement le nombre de 1 correspondant au nombre initial de bâtiments avec NumberofFloors inférieur ou égal à zéro. Contrôler que IsAggregatedCampus identifie correctement tous les bâtiments de type Campus. Valider que ces variables sont créées avant toute modification de la variable NumberofFloors elle-même. S'assurer que les deux flags sont de type binaire strict.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
7	NumberofFloors	Pour les lignes où NumberofFloors est inférieur ou égal à zéro, remplacer la valeur par NaN	<p>Pour les bâtiments déclarant zéro étage, la valeur zéro ne peut être maintenue car elle créerait des calculs de densité aberrants (surface infinie par étage) lors des analyses multidimensionnelles et de la détection d'outliers. Le recodage en NaN permet de traiter explicitement cette absence d'information plutôt que de conserver une valeur physiquement incohérente. Cette transformation préserve l'ensemble des autres variables de l'observation, notamment les consommations énergétiques et les surfaces qui restent exploitables. Les valeurs manquantes ainsi créées seront imputées ultérieurement en Section 1 par des méthodes statistiques basées sur la relation entre surface totale et nombre d'étages au sein de chaque catégorie d'usage.</p>	<p>Confirmer que tous les bâtiments avec zéro étage ont été recodés en NaN. Contrôler que le nombre de valeurs manquantes dans NumberofFloors a augmenté exactement du nombre attendu de conversions. Valider que les lignes recodées conservent toutes leurs autres variables intactes.</p>

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
8	SiteEUIWN(kBtu/sf), SourceEUIWN(kBtu/sf)	Recalculer les intensités énergétiques en divisant les consommations normalisées corrigées par PropertyGFABuilding(s) (reviens au meme que de le faire uniquement pour les batiments avec variables WN modifié	La correction des consommations Weather Normalized rend les intensités d'origine caduques. Le recalcul est indispensable pour restaurer la cohérence déterministe entre l'énergie et la surface. Le choix de PropertyGFABuilding(s) comme dénominateur, validé par une MAE de 0.00, garantit l'alignement strict avec la méthodologie de Seattle. Cette mise en conformité élimine le biais induit par les surfaces non chauffées (parkings) et fiabilise la détection ultérieure des outliers de performance.	Confirmer que le dénominateur utilisé exclut les surfaces hors-bâti pour maintenir la précision mathématique du ratio. Vérifier l'absence de valeurs infinies suite au recalcul et à leur remplacement par NaN. Contrôler que la corrélation entre les nouvelles intensités et les émissions de CO2 est renforcée. Valider la disparition des incohérences où l'énergie est positive mais l'intensité nulle.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
9	LargestPropertyUseTypeGFA, PropertyGFATotal	Calculer le ratio LargestPropertyUseTypeGFA divisé par PropertyGFATotal puis supprimer toutes les lignes où ce ratio est strictement supérieur à une valeur critique	Un ratio dépassant un certain seuil signifie que la surface déclarée pour l'usage principal excède la surface totale du bâtiment de manière inacceptable. Cette incohérence physique est jugée irrémédiable et ne peut résulter d'une simple imprécision de mesure. Conserver ces observations fausserait systématiquement le calcul de l'intensité énergétique par unité de surface en sous-estimant artificiellement la consommation réelle. Un dépassement au-delà du seuil introduit un biais trop important pour être compensé par quelque méthode statistique que ce soit.	Vérifier qu'aucune observation ne présente un ratio dépassant le seuil critique après suppression. Calculer le nombre exact de lignes supprimées pour cette raison et documenter leur répartition par PrimaryPropertyType. Contrôler que les distributions de LargestPropertyUseTypeGFA et PropertyGFATotal ne présentent plus de cas extrêmes au-delà du seuil critique. Valider que cette suppression est effectuée avant tout calcul d'indicateurs énergétiques dérivés.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
10	Electricity(kBtu), NaturalGas(kBtu), SteamUse(kBtu), SiteEnergyUseWN(kBtu)	Calculer la somme des trois sources énergétiques, puis calculer l'écart relatif absolu entre cette somme et SiteEnergyUseWN(kBtu), enfin supprimer toutes les lignes où cet écart relatif est strictement supérieur à 0.25 (on évite de supprimer trop de bâtiments)	La cohérence énergétique constitue un prérequis fondamental pour la validité des émissions de CO2 calculées. La municipalité de Seattle applique des facteurs d'émission spécifiques à chaque source d'énergie pour obtenir les émissions totales. Si la somme des sources énergétiques détaillées ne correspond pas au total déclaré avec un écart supérieur à dix pourcent, cela signale soit une source d'énergie majeure omise, soit une corruption des données de conversion. Un écart de cette amplitude ne peut être attribué à de simples arrondis lors des conversions d'unités. Conserver ces observations reviendrait à accepter des valeurs de CO2 mathématiquement corrompues, ce qui viderait de sens l'objectif même de prédiction des émissions.	Vérifier qu'aucune observation ne présente un écart énergétique supérieur à dix pourcent après nettoyage. Documenter précisément les bâtiments supprimés avec leurs écarts respectifs. Analyser la distribution des écarts résiduels pour confirmer qu'ils restent dans des plages acceptables. Valider que les observations conservées présentent une cohérence mathématique entre sources et total. Contrôler que cette suppression n'introduit pas de biais sectoriel en vérifiant la représentativité des types de bâtiments restants.

Section 3

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
11	SiteEUIWN(kBtu/sf)	Aligner l'intensité énergétique sur la surface bâtie (PropertyGFABuilding(s))	Cette étape préparatoire garantit que la détection d'outliers s'appuie sur une densité énergétique réelle, évitant que des erreurs de reporting de surface ne biaisent les seuils statistiques.	Validation de la cohérence entre les consommations synchronisées en Section 2 et le référentiel de surface bâti.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
12	Variables de volume (Z-score)	Calculer les Z-scores par PrimaryPropertyType et sommer les dépassements de seuil critique	Permet d'isoler les bâtiments dont les consommations globales sont aberrantes au sein de leur propre catégorie d'usage, sans pénaliser les secteurs naturellement énergivores.	Création de la feature extreme_zscore_count capturant le cumul des anomalies de volume.
13	Variables de structure (IQR)	Appliquer la détection IQR segmentée par usage sur les intensités et les surfaces	L'approche par quartile respecte l'hétérogénéité architecturale du parc. Elle cible spécifiquement les anomalies de ratio (EUI) et de dimensionnement (GFA).	Identification des flags is_iqr_outlier_ pour les variables critiques de performance et de taille.
14	Toutes variables techniques	Archiver extreme_zscore_count et supprimer les colonnes de calcul individuelles	On transforme une série de diagnostics binaires en un indicateur de fiabilité multidimensionnel conservé pour enrichir le signal du modèle de prédiction.	Nettoyage du dataset final tout en préservant le score d'anomalie agrégé comme feature d'entrée.
15	Lignes filtrées	Exclure les observations cumulant trop de Z-scores ou présentant un IQR critique, hors structures massives	Assure la pureté statistique du dataset en supprimant les corruptions de données, tout en protégeant les hôpitaux ou universités (massive_structures_types) dont la taille justifie l'écart.	Vérification de la réduction du bruit statistique et confirmation de la préservation des mégastructures légitimes.

Section 1 : Finalisation et Imputations en cascade

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
16	Outlier et ComplianceStatus	Supprimer toute ligne où la colonne Outlier est non vide ou ComplianceStatus n'est pas "Compliant"	Nous centralisons ici les décisions d'exclusion. La colonne Outlier récupère les anomalies statistiques de la Section 3, tandis que ComplianceStatus traite les défauts administratifs. Cette purge sécurise l'échantillon avant les phases d'apprentissage.	Vérifier que la colonne Outlier est vide et que ComplianceStatus est 100% conforme sur le dataset filtré.
17	SecondLargest...	Créer le flag IsMixedUse (1 si renseigné, 0 sinon) puis supprimer les colonnes sources	La présence d'un usage secondaire est un marqueur de complexité structurelle. Transformer cette donnée lacunaire en indicateur binaire permet de conserver le signal métier sans subir le poids des valeurs manquantes.	Vérifier la création du flag et la suppression des colonnes de surfaces secondaires.
18	ENERGYSTARScore	Créer le flag Has_EnergyStarScore avant toute opération d'imputation	L'absence de score n'est pas aléatoire (MAR). Le flag permet au modèle de détecter si l'absence d'information est corrélée à une performance énergétique spécifique, avant que la valeur ne soit complétée.	Confirmation que le flag binaire précède l'étape d'imputation.

Ordre	Variable cible	Action technique	Justification méthodologique	Validation attendue
19	Variables Numériques	Imputer en cascade : Médiane par PrimaryPropertyType , puis Médiane Globale	La cascade garantit la complétude du dataset. On privilégie la médiane du groupe d'usage pour respecter la morphologie du bâti, avec un repli sur la médiane globale pour les catégories sous-représentées.	Absence totale de NaN sur les variables numériques cibles.
20	NumberofFloors	Imputer en cascade (Usage > Global) avec arrondi à l'entier	Les étages sont une variable structurelle clé. L'imputation en cascade fiabilise cette donnée tout en assurant une cohérence physique (pas de demi-étage) via l'arrondi.	Validation des valeurs entières et de la cohérence avec les types de bâtiments.
21	Colonnes lacunaires	Supprimer définitivement les variables avec un taux de vide prohibitif (ex: Comments, 3rd Use)	L'élimination des colonnes trop creuses permet de réduire la dimensionnalité inutile et de se concentrer sur les variables ayant un fort pouvoir prédictif.	Liste des colonnes supprimées documentée dans l'audit.
22	Lignes vides (> 30%)	Exclusion finale des observations présentant un taux de vacuité résiduel supérieur au seuil critique	Ce filtre de sécurité rejette les bâtiments dont le profil reste trop incomplet malgré les imputations, évitant ainsi d'injecter du bruit dans le modèle de prédiction.	Contrôle du taux de remplissage final par ligne.