

# Dictionnaire des variables issues du nettoyage des données

---

## 1. Rappel conceptuel : qu'est-ce qu'une variable flag ?

Une variable flag est une variable binaire construite explicitement pour **signaler une situation particulière dans les données**, sans prétendre représenter directement une caractéristique physique ou économique du phénomène étudié.

Un flag n'a pas pour objectif principal d'expliquer la variable cible, mais de :

- tracer une **anomalie de déclaration**,
- conserver la mémoire d'une **correction ou d'une transformation appliquée**,
- distinguer des **cas structurellement non comparables**,
- contrôler un biais potentiel lié à la qualité ou à la granularité des données.

Ces variables peuvent être mobilisées à trois niveaux :

- **audit et diagnostic de la qualité des données**,
- **variables de contrôle** dans un modèle,
- **critères d'exclusion ou de stratification** lors des analyses.

Elles ne doivent pas être interprétées comme des variables structurelles, même si elles sont intégrées à un modèle statistique.

---

## 2. Variables créées lors du nettoyage

### 2.1 IsZeroFloorReported

Cette variable binaire indique si le nombre d'étages déclaré dans la base brute était nul ou non valide.

- Valeur 1 : `NumberOfFloors ≤ 0` dans les données initiales
- Valeur 0 : `NumberOfFloors > 0`

Cette variable ne décrit pas un bâtiment sans étage, mais une incohérence ou une absence d'information dans la déclaration initiale.

#### Cas d'usage

- En phase de nettoyage, elle permet de distinguer les observations pour lesquelles une correction ou une imputation du nombre d'étages a été nécessaire.
- En analyse exploratoire, elle sert à évaluer si les bâtiments présentant une mauvaise qualité déclarative ont un comportement énergétique ou des émissions atypiques.
- Dans un modèle de régression, elle peut être introduite comme **variable de contrôle**, afin d'absorber un effet lié à la qualité de la donnée, sans interprétation causale directe.

#### Recommandation d'utilisation

- Variable pertinente comme flag d'audit et de contrôle.
  - À ne pas interpréter comme une caractéristique physique du bâtiment.
  - À ne pas utiliser comme substitut du nombre d'étages.
- 

## 2.2 IsAggregatedCampus

Cette variable binaire identifie les observations correspondant à des entités agrégées de type campus.

- Valeur 1 : **BuildingType = Campus**
- Valeur 0 : autres types de bâtiments

Elle signale que l'observation regroupe potentiellement **plusieurs bâtiments hétérogènes**, partageant une consommation ou une surface agrégée.

### Cas d'usage

- En phase de nettoyage, elle permet d'éviter l'application de règles de correction ou d'imputation conçues pour des bâtiments unitaires.
- En analyse descriptive, elle autorise des comparaisons séparées entre bâtiments individuels et entités agrégées.
- Dans un modèle, elle peut être utilisée comme variable de segmentation ou de contrôle pour capter les effets d'échelle et de structure.

### Recommandation d'utilisation

- Variable essentielle pour la cohérence méthodologique.
  - À inclure systématiquement dans toute analyse mobilisant des variables structurelles (étages, surface, intensité).
  - À utiliser avec prudence dans les modèles prédictifs, compte tenu de la non-comparabilité structurelle avec les bâtiments unitaires.
- 

## 2.3 IsMixedUse

Cette variable binaire indique si un bâtiment possède un usage secondaire déclaré, signalant une mixité d'usages.

- Valeur 1 : **SecondLargestPropertyUseType** est renseigné dans les données initiales
- Valeur 0 : **SecondLargestPropertyUseType** est manquant (bâtiment mono-usage)

Cette variable capture l'information structurelle sur la mixité sans conserver les détails lacunaires des usages secondaires.

### Cas d'usage

- En phase de nettoyage, elle permet de préserver l'information sur la mixité tout en supprimant les colonnes originales à fort taux de valeurs manquantes.
- En analyse exploratoire, elle aide à distinguer les bâtiments mono-usage des mixtes pour évaluer les impacts sur la consommation énergétique.

- Dans un modèle, elle peut servir de variable explicative ou de contrôle pour capturer les effets de la complexité d'usage.

**Recommandation d'utilisation**

- Variable utile pour la segmentation des bâtiments par type d'usage.
- À interpréter comme un indicateur de structure plutôt qu'une mesure précise de mixité.
- À combiner avec **PrimaryPropertyType** pour des analyses plus fines.

---

## 2.4 **Has\_EnergyStarScore**

Cette variable binaire indique si le score ENERGY STAR était renseigné dans les données initiales.

- Valeur 1 : **ENERGYSTARScore** est renseigné
- Valeur 0 : **ENERGYSTARScore** est manquant

Cette variable flagge un pattern de valeurs manquantes potentiellement informatif, lié à un mécanisme MAR (Missing At Random) conditionné par **PrimaryPropertyType**.

**Cas d'usage**

- En phase de nettoyage, elle permet de capter si l'absence de score constitue un signal prédictif avant imputation.
- En analyse exploratoire, elle sert à évaluer les biais potentiels liés à la non-déclaration volontaire (risque MNAR).
- Dans un modèle, elle peut être utilisée comme variable de contrôle pour absorber les effets liés à la qualité de déclaration.

**Recommandation d'utilisation**

- Variable pertinente pour l'audit des patterns de valeurs manquantes.
- À créer avant toute imputation de **ENERGYSTARScore**.
- À ne pas interpréter comme une mesure de performance énergétique, mais comme un indicateur de fiabilité déclarative.

---

## 2.5 Synthèse des nouvelles variables

Nom de la variable	Type	Nature	Finalité principale
IsZeroFloorReported	Binaire	Flag	Qualité de déclaration
IsAggregatedCampus	Binaire	Flag	Granularité / structure des données
IsMixedUse	Binaire	Flag	Mixité d'usages
Has_EnergyStarScore	Binaire	Flag	Pattern de valeurs manquantes

---

## 3. Variables supprimées lors du nettoyage

Certaines variables ont été exclues du jeu de données nettoyé pour des raisons méthodologiques clairement identifiées. Ces suppressions visent à améliorer la stabilité des analyses et la lisibilité des modèles.

Les catégories de variables supprimées incluent notamment :

- **Variables à taux de valeurs manquantes extrêmes** : Colonnes avec une densité d'information insuffisante ( 100% ou >94% de manquants), rendant toute imputation non crédible et alourdissant le pipeline sans valeur ajoutée.
- **Variables redondantes ou à faible valeur discriminante** : Colonnes singleton ou structurellement liées à d'autres, remplacées par des flags pour préserver l'information essentielle.
- **Variables temporaires pour diagnostic** : Utilisées pour validation puis supprimées avant modélisation pour éviter la redondance.

Liste exhaustive des variables supprimées :

Nom de la variable	Raison de suppression	Ordre concerné
Comments	Taux de valeurs manquantes de 100% ; aucune information exploitable.	4
YearsENERGYSTARCertified	Taux de valeurs manquantes de 94,26% ; densité résiduelle insuffisante pour modélisation.	4
Outlier	Taux de valeurs manquantes de 98,99% ; utilisée temporairement pour diagnostic des aberrants, puis supprimée avant entraînement.	5
ThirdLargestPropertyUseType	Taux de valeurs manquantes de 78,18% ; dépendance structurelle avec usages secondaires ; information compensée par <b>IsMixedUse</b> .	6
ThirdLargestPropertyUseTypeGFA	Taux de valeurs manquantes de 78,18% ; même justification que ci-dessus.	6
SecondLargestPropertyUseType	Taux de valeurs manquantes de 47,75% ; information transformée en <b>IsMixedUse</b> binaire ; suppression pour éviter lacunes.	7
SecondLargestPropertyUseTypeGFA	Taux de valeurs manquantes de 47,75% ; même justification que ci-dessus.	7

La suppression de ces variables n'implique pas une perte d'information substantielle, mais au contraire une **réduction du bruit statistique** et des risques d'instabilité des estimations.

## 4. Positionnement méthodologique

Les variables introduites à ce stade relèvent d'une **logique de traçabilité et de contrôle**, et non d'enrichissement explicatif direct. Leur rôle est de garantir que les décisions de nettoyage, d'imputation ou d'exclusion restent observables, justifiables et reproductibles.

Elles constituent un socle méthodologique indispensable pour :

- documenter les choix de préparation des données,
- sécuriser l'interprétation des résultats,
- renforcer la crédibilité statistique et scientifique de l'analyse.